Progress Report

김강민, 김동현, 박주영 (12조)

1. 문제 정의

1.1 주식 데이터의 특성 및 문제 정의

주식 시계열 데이터는 낮은 신호 대 잡음비로 인해 지도학습용 라벨 확보가 어렵고, 장기적인 추세, 주기성 등 복잡한 패턴을 가지고 있어 라벨링을 통한 지도 학습 (Supervised Learning)에 어려움을 겪는다. 또한, 기존의 예측 모델이 결과에 대한 해석 가능성이 낮은 블랙 박스 모델이라는 한계점이 있다. 이 한계점으로 인해 시장 및 투자자에게 모델이 활용됨에 있어 필수적인 투명성 요건을 충족하지 못한다. 모델을 통한 예측을 실제 시장에서 활용하기 위해서는 왜 특정 주식을 매수/매도 해야 하는지에 대한 합리적인 근거 제시가 필수적이다. 따라서 본 프로젝트에서는 주식 시계열 데이터에 자기 지도 학습(Self-Supervised Learning)을 적용하여 주식 데이터의 유용한 표현을 학습하는 동시에, 그 학습된 표현에 대해 설명가능성을 확보하는 것을 목표로 한다.

1.2 데이터 선정 및 프레임워크 정의

데이터로 이용하는 종목(지수)의 특성이 모델의 특성을 LLM(Large Language Model)으로 설명하는 능력의 성능에 큰 영향을 준다. 따라서 어떤 데이터를 이용해 모델을 학습시킬지를 숙고할 필요성이 있다. 주식 시장에서 Nvidia, Apple, 삼성전자 등의 개별 종목은 기업 고유의 이슈, 재무 구조, 산업별 사이클 등으로 인해 변동성이 크고 비정형적인 움직임을 보인다. 즉, 거시적인 경제흐름과 종목의 특정성을 동시에 고려해야 좋은 모델을 만들 수 있다.

일반적으로 경제지는 당일에 큰 움직임을 보인 종목들이나 섹터를 주로 다루고 그 이외에는 전체적인 시장 동향을 다루게 된다. 따라서, 특정 종목에서 움직임이 약한 구간이 나타나게 되면, 이 구간을 학습시키기 위한 적절한 텍스트 데이터를 구하는 것에 어려움을 겪을 수 있다.

경제지가 가진 텍스트의 성격을 고려해 보았을 때, 본 프로젝트에서는 시장 전체의 동향을 대표할 수 있는 데이터셋을 선정하는 것이 타당하다. 따라서, 미국 S&P 500 지수를 추종하는 ETF인 "SPDR S&P 500 ETF Trust (SPY)"의 시계열 데이터를 사용하기로 결정하였다. SPY는 세계에서 거래량이 가장 많고, 미국 주식시장의 전반적인 흐름을 반영하는 대표 지수형 자산으로 널리 활용된다. SPY는 S&P 500 지수를 구성하는 약 500개 대형주들의 시가총액 가중 평균을 기반으로 하며, 개별 기업의 특수 요인보다는 시장 전반의 거시적 트렌드와 투자 심리를 반영한다. 또한 SPY는 1993년부터 현재까지 장기간의 고품질 데이터를 제공하며, 높은 유동성과 안정적인 가격 형성 구조로 인해 실험 데이터로

적합하다. 따라서 본 프로젝트에서는 SPY의 OHLCV(Open, High, Low, Close, Volume) 시계열 데이터를 입력으로 활용하여, 시장 전반의 변동성과 주기성을 포괄하는 자기 지도 학습 기반 표현 학습을 수행한다.

2. 시도한 방법론 소개

2.1 데이터 및 전처리

데이터는 SPY의 OHLCV 시계열 데이터로 구성했으며, 2023년과 2024년 2개년의 SPY 주가 정보를 30분 간격으로 측정한 데이터를 사용하였다. 각 샘플은 13개의 30분봉 데이터 (하루 데이터)로 이루어져 있으며, 하루 단위 정규화를 적용해 동일 일자 안에서 OHCLV 값 각각을 0에서 1 사이의 상대적 척도로 변환했다. 이 방식은 절대적 가격 수준이나 거래량 규모 대신 하루 내에서의 상대적 구조, 예컨대 고저 대비 종가의 위치나 체결 강도의 상대 크기와 같은 패턴에 집중하도록 모델을 학습시키려는 의도이다.

2.2 모델

모델은 1차원 VQ-VAE 구조를 채택했다. Encoder는 1D convolution layer와 ReLU를 적층해 input data를 latent dimension으로 투영하면서 시간의 해상도를 점진적으로 낮추고 이 latent vector를 Vector VQ(Vector Quantizer)에 전달한다. VQ는 학습된 codebook에서 각 latent vector의 값과 가장 가까운 code를 선택해 연속적인 값들을 이산적인 codebook index vector로 치환한다.

이 과정에서 VQ-VAE 모델은 reconstruction, vector quantization, codebook commitment loss 총 세 개의 loss term을 이용해 표현 손실을 최소화하면서도 중복을 줄이도록 학습된다. 이 때, 하이퍼파라미터를 통해 vector quantization, codebook commitment loss 사이의 비율을 조정해 encoder의 출력이 codebook 표현에 과도하게 수렴하거나 멀어지지 않도록 한다. Decoder는 transposed convolution을 통해 낮아졌던 시간 해상도를 원래 길이로 복원하고, channel dimension을 input의 OHLCV dimension으로 되돌려 입력을 재구성한다.

최적화는 Adam optimizer를 사용했고 학습률과 에폭 수, 배치 크기 등은 Wandb를 이용해 재현 가능성 및 비교 용이성을 확보했다. 학습 중에는 학습, 검증 데이터에 대한 loss들을 기록했으며, codebook의 사용률과 같은 품질 지표도 함께 기록하여 codebook의 bias, dead code의 발생 여부를 확인할 수 있도록 했다. 또한, 하이퍼파라미터 튜닝을 통해 성능을 평가할 수 있도록 파이프라인을 구성하였다.

2.3 토큰 시퀀스 관찰과 활용 준비

모델의 output인 discrete index sequence는 input과 downstream 과제를 연결하는 핵

심적인 매개체이다. 이 단계에서는 특정 code에 대응하는 sample들을 모아, 이 sample들이 나타내는 구간들의 가격 흐름들을 나란히 관찰했다. 이를 통해, 흐름의 추세나 변동성 확대 구간 등 sample들 사이에서 공통적으로 나타나는 가격의 특성을 확인했다.

2.4 추후 계획

Progress Report 이후에는 모델을 통해서 알아낸 데이터셋을 잘 표현할 수 있고, VQ-VAE Embedding Space의 latent dimension에 대해 적절한 크기를 지닌 LLM을 채택한다. 그 후, 이코노미스트, 월스트리트 저널과 같은 경제지에 대한 텍스트와 VQ-VAE의 임베딩 공간을 정렬시킨다. 이후의 프레임워크에서는 특정 날짜의 주가 시계열 데이터를 입력하면 이를 사람이 이해할 수 있는 텍스트로 분석해주는 모델을 만드는 것을 목표로 한다.

3. 중간 결과 및 해석

3.1 Training and Validation Results

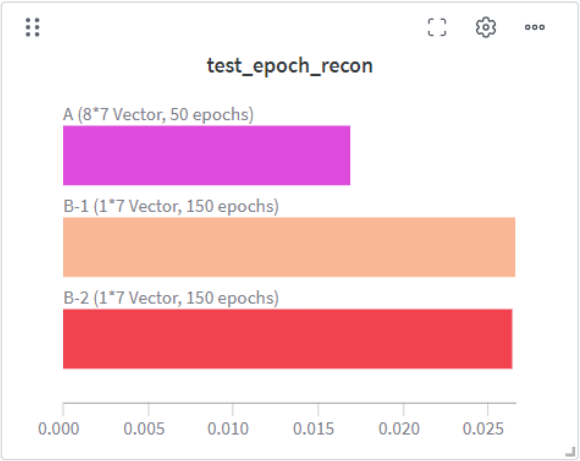

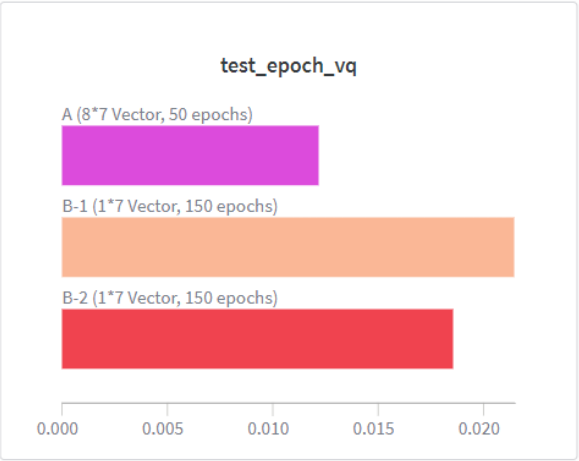

위 그래프는 VQ-VAE 모델을 각 샘플 데이터를 임베딩 하는 방식에 차이를 두어 학습을 진행하였을 때의 결과를 나타내는 막대 그래프이다. 'test_epoch_recon'은 테스트 세트에 대한 reconstruction error의 값을, 'test_epoch_vq'는 테스트 세트에 대한 vector quantization loss와 codebook commitment loss 값의 합으로, codebook 선택 및 commit 과정에서의 불일치를 나타낸다. 또한, 임베딩 과정에서 A는 하루에 해당하는 데이터를 8X7 차원으로, B는 8X1 차원으로 축소시켰을 때의 결과값을 나타낸다. 추가로, A와 B의 경우 모두 검증 세트에 대한 reconstruction error가 안정적으로 수렴한 결과를 보였다.

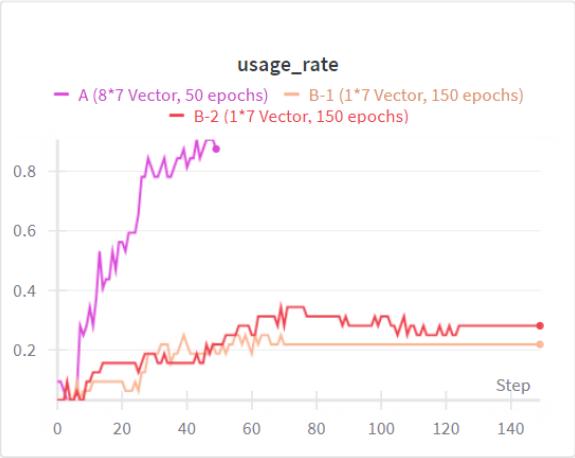

'usage rate'는 codebook의 index 중에서 사용되고 있는 codebook의 비율을 나타내는 지표이다. A와 B를 비교하면, 당연하게도 데이터가 더 적은 차원으로 축소됨에 따라 B의 usage rate가 A의 usage rate보다 작게 나타난다. 물론 usage rate는 모델의 성능과 직결되는 부분이 아니므로, 이를 모델 성능에 큰 영향을 주는 지표로 보아야 할지에 대해서는 고민해볼 필요가 있다.

하지만, A의 전체적인 error에 대한 지표 또한 모두 B보다 낮은 모습을 보여주고 있다. 이 또한 각 벡터가 가지고 있는 정보의 양에 따라 당연하게 나타나는 차이이지만, 현저하게 낮은 error 지표를 보여주고 있기 때문에 이에 대해 생각해 볼 필요가 있다. A의 경우에는 8X7 차원의 벡터로 축소된 값을 이산화하여 한 샘플당 7개의 embedding index가 나오므로 우리의 목적과는 맞지 않는다. 하지만, 이 7개의 embedding index 값으로 각 벡터 사이의 similarity를 계산하여 클러스터링 하는 등의 이 값들을 활용한 방식을 통해 우리의 목적에 맞게 사용할 수 있을지 논의해 볼 필요가 있다.

B의 error에 대한 지표를 자세히 살펴보았을 때, reconstruction error는 MSE값을 사용했으며 test reconstruction error는 약 0.026를 기록하였고, 따라서 RMSE는 0.161로 나타난다. 이는 데이터 정규화를 고려했을 때 직관적으로 하루 고저폭을 1로 본 상대 좌표계에서 약 16% 정도의 편차가 발생함을 의미하고, 모델이 재구성 과제에서는 적당한 수준의 복원력을 갖추었다고 할 수 있다. 자세히는, 모델이 하루의 고저 대비 종가의 위치나 가격의 흐름 등 상대적 구조를 잘 따라가고 있지만, 급격한 변동성이 나타나는 구간이나, 미세한 차이에서는 아직 오차가 누적될 여지가 남아있는 상태라고 해석할 수 있다.

반면에, test vq error는 0.02를 기록하였다. B의 reconstruction error와 큰 차이가 나지 않는다는 점에서, encoder가 codebook 기반의 제약을 반영하면서 표현을 구성하고 있다는 것을 알 수 있다. B의 usage rate를 함께 고려하여 생각했을 때, codebook 기반의 표현을 실질적으로 활용하고 있으나, 일부 code에 집중되는 경향이 남아 있음을 알 수 있다.

3.2 Distribution of Codebooks and Semantic Analysis

(A)

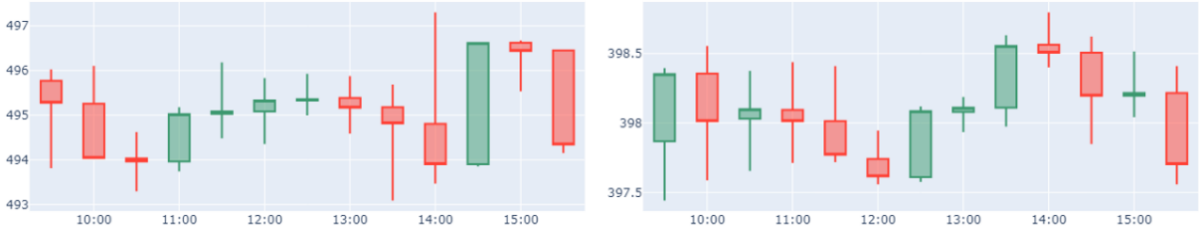

(B)

위의 2개의 차트는 무작위의 공통된 codebook index에서 추출한 샘플들을 각각 2개씩 candle stick 차트로 나타낸 것이다. (A)의 경우에는 한 codebook에 15개의 샘플이 속한 반면, (B)의 경우에는 한 codebook에 4개의 샘플이 속했다. Uniform한 데이터들의 경우, 같은 codebook index에 속하는 샘플들의 개수가 uniform하게 나타나는게 바람직하지만, 주식 데이터의 특성상 (B)와 같이 변동성이 큰 샘플의 수가 (A)와 같은 변동성이 작은 샘플의 수보다 작을 것이고, 이처럼 불균형한 분포가 나타날 수 있다.

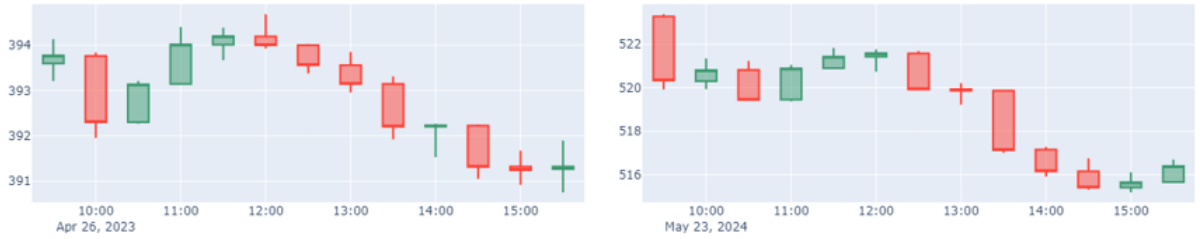

(C)

(D)

(C)와 (D)는 각 샘플들의 날짜에 해당하는 경제지 1면의 기사이다. (C)는 모두 하락하는 추세를 보이고 있다. 우측에 해당하는 EU와 중국의 관세 전쟁은 급격히 하락하는 추세선을 뒷받침하기에 충분한 근거가 되지만, 좌측에 해당하는 투자 유치 관련 기사는 추세를 뒷받침하기에는 어려운 부분이 있다고 보여진다. 따라서 추후에 LLM을 학습하는 과정에서 SPY 지수의 추세를 뒷받침할 수 있는 양질의 경제지 텍스트 데이터를 가공하여 학습하는 과정이 요구된다.

4. 개선이 필요한 부분과 개선 계획

A) 데이터 전처리 과정에서 Min-Max Scaling을 이용하였는데, Z-Score Scaling과 같은 다른 매소드를 사용해 볼 여지가 존재한다. 또한, 하루 단위로 정규화를 한다는 점에서, 전체 주가와 관련된 global context가 많이 희석될 수 있다. 그러므로, VQ-VAE가 local context에 집중하여 학습하였을 경우와 global context를 함께 학습하였을 경우에 따른 LLM의 output의 정확도의 차이를 확인해 볼 필요가 있다. 주식 데이터가 정치, 사회적인 상황이 두번이상 반복되지 않는 stream 형태의 데이터임을 고려했을 때, global context와 local context를 나타내는 파라미터를 조정해 가며 모델의 성능적인 측면을 확인할 필요가 있다.

B) 현재는 한 codebook에 속하는 샘플 개수가 비슷하지 않고, 특정 codebook의 샘플 개수가 큰 모습을 보이기도 한다. 앞서 서술했듯이 이는 데이터의 특성으로 인해 나타나는 것일 수도 있다. 하지만, 데이터의 특성과 별개로, VQ-VAE가 샘플 데이터를 잘 분류하지 못하여 생겨나는 현상일 가능성 또한 존재한다. 3.1의 usage_rate 그래프를 보았을 때, 실제로 데이터를 8x1 차원까지 축소시킨 경우에는 usage rate가 20퍼센트 근방정도로 형성되어 embedding space 전체를 잘 활용하지 못하는 모습을 보인다. 이를 보정하

기 위해서 코드북의 볼륨에 따른 페널티를 학습 과정에서 추가해 모델의 성능 변화를 확인해 볼 필요가 있다.

C) VQ-VAE는 latent vector를 가장 유사한 codebook으로 양자화하는 매커니즘을 가지고 있다. 우리 모델은 각각의 벡터들이 cosine similarity가 가장 높은 codebook에 embedding 되도록 학습되었다. 하지만, 해석하는 관점에서는 단지 각각의 벡터들의 정량적 유사도를 확인하는 것을 넘어, 해당 codebook 클러스터가 실제 데이터의 의미를 표현하는지 확인하는 과정이 필요하다. 즉, 특정 codebook에 해당하는 벡터들이 실제 세계의 의미를 담고 있는지, LLM으로부터 산출되는 데이터와 유사한 내용을 담고 있는지 교차 검증하는 단계가 필요하다.

D) 현재 502일의 SPY 주가 데이터를 이용해 모델 학습을 진행했는데, 이에 대한 VQ-VAE 모델의 크기가 적절한지에 대해 확인할 필요가 있다. 모델의 encoder, decoder의 layer 수, embedding space에 대한 값과 같이 모델의 구조, 크기나 데이터 셋의 규모를 조절해 가면서 ablation study를 진행해볼 필요가 있다.

E) 모델을 훈련할 때에 한 codebook 내에 속한 벡터들이 의미 있는 클러스터를 형성했는지, 그에 대응하는 주가 데이터에 대한 해석이 텍스트로 적절하게 나타나고 있는지에 대해 평가하는 과정이 필요하다. 하지만, 이때 나타나는 문제의 원인이 데이터가 본래부터 가지고 있던 한계인지, 모델 고유의 loss인지 구분하기 어려울 수 있다. VQ-VAE가 SSL을 통해 샘플들을 잘 분류하였더라도, LLM이 가진 데이터들이 그 내용을 설명하기에 부족할 수 있기 때문이다. 이를 위해서는 VQ-VAE와 Fine-tuned LLM이 잘 정렬되었는지 실험적으로 검증하는 과정이 필수적이다. 따라서, SPY 주가 데이터를 잘 설명할 수 있도록 data augmentation 등의 방법을 이용해 데이터를 구성하고, ablation study를 통해 궁극적인 목표인 설명 가능한 주가 분석 모델을 구축할 것이다.